

GFP高亮度与热稳定性联合设计：三策略生成 + 分层筛选管线

一、项目概述

1.1 竞赛任务

1.2 设计方法概述

策略 A（理性枚举）：45 个候选位点，2-3 点突变组合，FoldX $\Delta\Delta G$ 验证。提供确定性保底。

策略 B（机器学习集成）：ESM-2 650M 嵌入 + XGBoost/LightGBM/Random Forest 集成 ($R^2=0.712$)。对所有候选序列预测亮度，驱动漏斗排序。

策略 D（进化共识分析）：135 条 GFP 同源序列 MSA $\rightarrow$ 保守性评分 + 上位性检测 + 特征嫁接。提供独立于物理力场的进化稳定性信号。

策略 C（ProteinMPNN 逆折叠）：基于 sfGFP 骨架 (2B3P) 的 AI 逆折叠设计。提供方法论多样性。

二、最终6条序列及选择依据

2.1 选择方法论：分层筛选

最终 6 条序列通过分层筛选 (Layered Filtering) 确定：每策略独立筛选，每个槽位有明确的单目标优化方向，每一步有科学可辩护的阈值。该方法避免自编综合公式的黑箱性，也避免了跨策略统一 P 四级证据体系（仅使用实际完成计算的数据）：

证据
可靠性
适用策略
实际覆盖
FoldX $\Delta\Delta G$
高（经验力场， ≤ 3 突变 RMSE ~ 1.6
A, D
A: 2,316 条, D: 277 条
ML 集成亮度 ($R^2=0.712$)
中（avGFP $\rightarrow$ sfGFP 域偏移）
A, D
ESM-2 650M + XGB/LGBM/
进化共识
高（135 条 GFP 同源 MSA，独立于
D
位点保守性评分
ProteinMPNN score
中（序列恢复概率）
C
271 条设计
选择流程： 策略D (277条) $\rightarrow$ [consensus最高(ddG<2.0)] $\rightarrow$ [consensus次高(位点独立)] 策略C (271条) $\rightarrow$ [L2 ≤ 2 + mpnn最高] $\downarrow$ 跨策略检查（策略覆盖 ≥ 3 ，位点分散） $\downarrow$ 最终6条 (3A+2D+1C)
阈值
依据

ddG
FoldX ΔΔG 预测 RMSE~1.6,
ddG
D 依赖进化信号为主, ddG 仅用于排除明确
ML>3.0
A 池前 18.9% 分位, 约 3 倍 WT
ML>3.5
A 池前 ~5% 分位, 极高亮度候选
ML>1.5 (D)
D 池中位数以上, 排除 ML 预测极端低值
consensus>0.3
信息论: 低于 0.3 表示位点在进化中高度可
L2≤2
≤2/5 个发色团氢键位点被突变

2.2 最终6条序列

#
Seq_ID
策略
突变
ML亮度
ddG
cons/mpnn
选择理由
1
SA_1149
A
S72T:H231F
4.024
-1.46
—
ML亮度最高
2
SA_1150
A
S72T:H231N
4.018
-1.86
—
最低ddG (ML>3.0+L2=0)
3
SA_2069
A
I152M:D190N
3.813
1.01
—
位点多样性 (与A1/A2不重叠)
4
SD_0000
D
L137M:I161L
1.836
1.75

cons=0.809
进化共识最强
5
SD_0006
D
L18M:L137M
1.913
0.87
cons=0.707
进化共识次强（位点独立）
6
SC_C_0042
C
84突变
—
—
mpnn=0.778
L2安全+mpnn最高

2.3 每条的科学依据

2.4 跨策略组合逻辑

维度
覆盖
设计意图
策略多样性
3A + 2D + 1C = 3 种策略
超过竞赛 ≥3 种要求
方法论正交
FoldX 力场(A) + ML 数据驱动(
四种独立方法论，避免单点失效
亮度梯队
Seq1(4.024)+Seq2(4.018
2 条极亮序列冲击金牌
稳定性梯队
Seq1(-1.46)+Seq2(-1.86
2 条预测比 WT 更稳定
A 突变位点
{72,231} × 不同化学(F vs N
位点分散，231 位点双策略
D 共识梯队
cons=0.809(#1) + cons=
D 池共识 Top 2

2.5 局限性声明

ColabFold 结构验证未完成：因 GPU 云实例在截止前终止，结构预测数据为 mock。当前依赖 FoldX ddG 作为稳定性主判据，其在 ≤3 突变范围内经过验证（RMSE~1.6 kcal/mol），但对策略 C 的 84 突变超出可靠范围，mpnn_score 仅作为参考。

策略 D 的 ML 亮度系统性偏低：D 候选 composite_score (~1.7-1.9) 比 A 候选 (~3.6-4.0) 低约一倍，更可能反映 ML 模型的训练分布偏移（avGFP→sfGFP），而非实际生物学亮度差异。D 序列的排序不依赖 ML 绝对值。

策略 B 无独立生成序列：B 的贡献通过 ML 模型对所有候选的排序体现，最终 6 条中 Seq1 为纯 ML 视角选出。

A1 与 A2 序列高度相似（99.6%）：两者仅差 231 位点（F vs N）——这是有意设计的化学策略对照，而非选择冗余。

三、三级约束体系

3.1 约束分级总览

约束级别
位点数
位点列表
约束类型
设计含义
一级
6
T65, Y66, G67, R96, E2
化学绝对约束，固定不可变
保护发色团形成和荧光产生的化学必要条件
二级
5
Q69, Q94, H148, T203,
量子产率优化约束，可探索但需补偿（≤2突变）
单点突变降低量子产率但可协同补偿
三级
~227
其余所有位点
结构验证约束，不预先禁止
事后通过 FoldX ddG 验证结构完整性

3.2 一级约束：化学绝对约束

3.3 二级约束：量子产率优化约束

位点
残基
化学角色
Q69
Gln
发色团酚氧氢键供体/受体，参与激发态质子转移
Q94
Gln
发色团 π 堆积，调控激发态非辐射衰减
H148
His
荧光淬灭通道（光诱导电子转移 PET），mB
T203
Thr
发色团酚氧氢键，调控发射波长和量子产率
S205
Ser
发色团局部介电环境调控，影响 Stokes

3.4 三级约束

四、策略设计

4.1 策略 A：理性枚举

4.2 策略 B：机器学习集成预测

模型
R²
Pearson r


RMSE
XGBoost
0.654
0.809
0.624
LightGBM
0.646
0.805
0.630
Random Forest
0.456
0.675
0.782
Simple Avg Ensemble
0.712
0.844
0.565

4.3 策略 D: 进化共识分析

4.4 策略 C: ProteinMPNN 逆折叠

4.5 母序列选择

五、漏斗筛选管线



5.1 Phase 1: 合规筛选（已完成，真实数据）

1. 长度 220-250 aa (全部通过, 所有设计均为 238aa)
2. 仅 20 种标准氨基酸大写字母, 以 M 开头 (全部通过)
3. L1 约束: T65/Y66/G67/R96/E222 固定 (在策略 A/D/C 生成阶段已保证)
4. Exclusion_List: 与官方 135,415 条排除序列做完全一致性比对, 无匹配
5. 精确去重: 按序列字符串精确去重

5.2 Phase 2: ML 亮度排序 (已完成, 真实数据)

输入: Phase 1 的 $\sim 2,500$ 条合规候选。

方法：策略 B 的 ML 集成模型 (XGBoost + LightGBM + Random Forest, $R^2=0.712$) 对所有候选预测亮度 (composite_score)。

策略多样性保护：为避免 ML 模型的系统性偏差（倾向给策略 A 序列高分，D 序列 lowball），引入策略配额——Top 80 中 A 占 53 条（66%）、D 占 25 条（31%）、C 占

5.3 Phase 3-5: 分层筛选（核心创新）

Phase 3 (ColabFold 结构验证) 和 Phase 4 (ThermoMPNN 稳定性预测) 因 GPU 云实例终止未完成 GPU 计算。在实际执行中, 我们跳过 mock 数据依赖的 Phase 5 分层筛选 (详见第二节) 使用四项已完成计算的真实数据——FoldX ddG、ML brightness、进化共识和 ProteinMPNN score——通过分层阈值 + 单目标排序选出

六、数据来源与可靠性

6.1 训练数据来源

Tier 1 — 实验验证结构数据（高可靠性）：	
数据	
来源	
性质	
sfGFP 晶体结构	
PDB 2B3P (Pédelacq et	
X 射线晶体学，分辨率 1.45 Å	
GFP 发光机制	
文献综述 (Tsien 1998, Annu	
多年多实验室验证	
Tier 2 — 高通量实验数据（中等可靠性）：	
数据	
来源	
性质	
Sarkisyan 2016 全量	
Sarkisyan et al. 2016,	
avGFP 54,026 条突变体荧光测量	
FPhase GFP 光谱	
fphbase.org	
社区维护数据库，~1,110 条记录	
Tier 3 — 计算预测数据（需独立验证）：	
数据	
来源	
性质	
FoldX ΔΔG	
本项目 (FoldX 5.1)	
经验力场，已与实验数据集对比（单点突变 RM	
ESM-2 嵌入	
本项目	
预训练蛋白语言模型	
ML 亮度预测	
本项目 (XGB/LGBM/RF 集成)	
训练于 Sarkisyan 2016, R² =	

6.2 关键警示

avGFP vs sfGFP 的序列差异：策略 B 的 ML 模型训练数据来自 avGFP（与 sfGFP 有 ~14 个氨基酸差异），存在系统性的结构域偏移。通过 ESM-2 650M 预训练嵌入和
计算预测 ≠ 实验值：FoldX ddG 和 ML composite_score 均为计算预测值，用于相对排序和风险分层，而非预测实验 Score 的绝对值。
Cell-Free 表达体系的特殊性：竞赛采用 Cell-Free 体系，而我们使用的训练数据 (Sarkisyan 2016) 来自 E. coli 体内表达。两者在蛋白折叠环境、分子伴侣可用性和氧化还

七、实际执行中的风险与应对

在原计划中，ColabFold 结构预测和 ThermoMPNN 稳定性预测计划在 AutoDL RTX 3090 云实例上完成。该实例在截止前终止，导致这两项数据未完成。
对最终选择的影响：
- 结构验证 (ColabFold) 未完成 → 依赖 FoldX ddG 作为稳定性主判据
- ThermoMPNN ΔTm 未完成 → 不依赖该数据
- 以上两项在候选筛选阶段并非核心依据——策略 A/D 的 2 突变序列在 FoldX 可靠范围内 (≤3 突变)，FoldX ddG 作为稳定性排序代理是够用的
已主动放弃的模块（时间和资源约束下的取舍）：
- 72° C GROMACS MD 模拟：200-300 元，2-3 天，计算成本远超排序信息的边际收益

- 策略 E (ESM3 Gibbs 采样生成)：GPU 时间 + HuggingFace 许可
- BioEmu 300K 构象系综：仅 300K，不能预测 72° C 行为

最低保障路线：在任何 GPU 不可用的情况下，策略 A 的 FoldX 验证结果（2,424 条通过）本身即可支撑 6 条合理序列的提交。实际最终 6 条的选择即在此保障路线上完成，额外整合了策略 D

八、参考文献

Sarkisyan, K. S., et al. (2016). Local fitness landscape of the green fluorescent protein. *Nature*, 5
Pédelacq, J. D., et al. (2006). Engineering and characterization of a superfolder green fluorescent
Rives, A., et al. (2025). ESM3: Simulating 500 million years of evolution with a language model. *Sci*
Dauparas, J., et al. (2022). Robust deep learning-based protein sequence design using ProteinMPNN. *S*
Schymkowitz, J., et al. (2005). The FoldX web server: An online force field. *Nucleic Acids Research*,
Lin, Z., et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a langu
Marks, D. S., et al. (2011). Protein 3D structure computed from evolutionary sequence variation. *PLo*
Tsien, R. Y. (1998). The green fluorescent protein. *Annual Review of Biochemistry*, 67(1), 509-544.
Ormö, M., et al. (1996). Crystal structure of the Aequorea victoria green fluorescent protein. *Scien*
Kato, K., & Standley, D. M. (2013). MAFFT multiple sequence alignment software version 7. *Molecular*
Eddy, S. R. (2011). Accelerated profile HMM searches. *PLoS Computational Biology*, 7(10), e1002195.

附录 A：策略产出统计

策略
生成方法
候选总数
FoldX 通过
通过率
ddG 均值
A
理性枚举（45 位点，2-3 点突变）
3,499
2,424
80.0%
~1.3
B
ML 集成（ESM-2 650M + XGB
2,834（A+D 打分）
—
—
—
D
MSA 保守性 + 特征嫁接 + 上位性
436
295（ddG
67.7%
0.97
C
ProteinMPNN 逆折叠
273
—
—
—

附录 B：约束位点总表

约束级别
位点
残基
约束类型
化学机制
L1
65
Thr
固定
发色团形成所需的环化亲核攻击
L1
66
Tyr
固定
发色团前体， π 共轭体系来源
L1
67
Gly
固定
最小空间位阻确保环化可行性
L1
96
Arg
固定
广义碱催化，Y66 C α 脱质子
L1
222
Glu
固定
广义酸催化，O 氧化脱氢
L1
CR0
发色团
固定
荧光来源的 π 共轭体系
L2
69
Gln
可探索
发色团酚氧氢键，ESPT
L2
94
Gln
可探索
发色团 π 堆积
L2
148
His
可探索
荧光淬灭通道（PET）
L2
203
Thr
可探索

发色团氢键，光谱调谐
L2
205
Ser
可探索
发色团微环境介电调控

本设计文档基于实际执行的精简管线（2026-06-30）。所有数据、模型性能指标和筛选统计均来自自己完成的实验运行。未执行或未完成的模块（ColabFold、ThermoMPN、MD、BioEmu、策